Rapport Introduction à l'apprentissage

CARON Frédéric CHARLES Mickaël

Table des matières

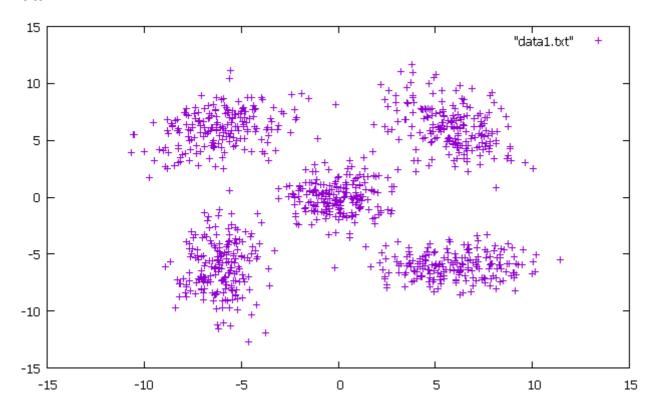
Classification des données bidimensionnelles	3
Observations	3
Data1 :	3
Data2 :	4
Data3 :	5
Première approche : les k-means	6
Data 1 :	7
Data 2 :	8
Data 3 :	9
Étude des données du sonar	10
Classification	10
Discrimination	10
Spike-Timing-Dependent Plasticity	11
Classification de signaux de parole	11

Classification des données bidimensionnelles

Observations

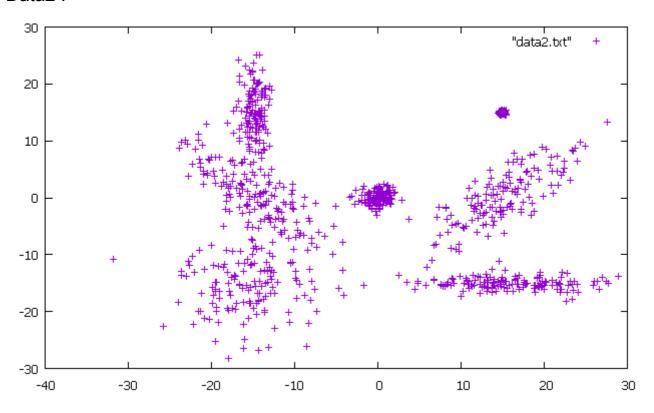
Les données des quatre fichiers appartiennent à R. Celles de data1 et data3 semblent être comprises entre -10 et 10 alors que celles de data2 entre -30 et 30. Grâce au logiciel de visualisation gnuplot nous pouvons facilement afficher les nuage de points que forment les données dans un repère cartésien.

Data1:



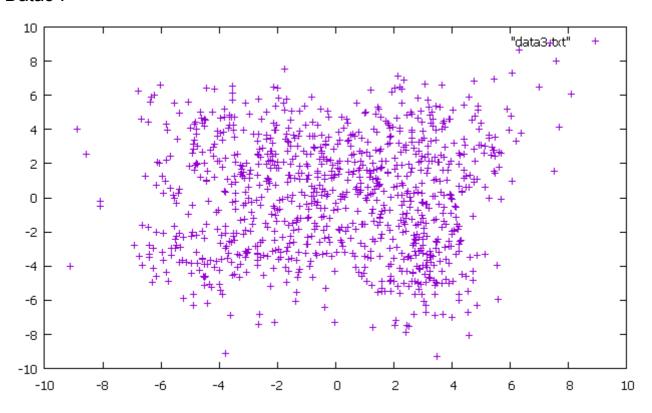
On distingue aisément cinq nuages de points qui ne se recouvrent pas. La classification ne devrait donc pas être trop difficile.

Data2:



Ici on peut observer des classes de formes différentes avec peut être du recouvrement sur la partie gauche, nous préconisons donc l'utilisation des nuées dynamiques, ou des centres mobiles flous.

Data3:



Sur le graphe du troisième jeu de donnée, nous ne voyons qu'un gros nuage de points homogène où il semble bien difficile de faire de la classification.

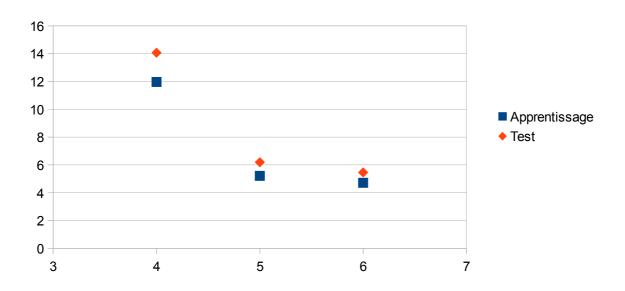
Les données de data4d sont décrites par quatre réels et ne sont donc pas objectivement observable dans un espace de taille 2 voir 3.

Première approche : les k-means

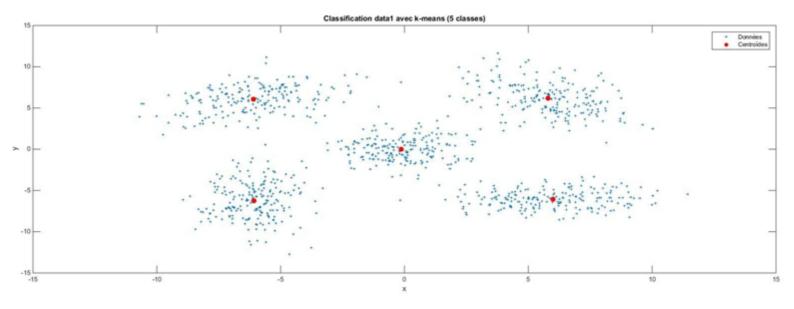
Pour les trois fichiers de données, nous utiliserons 66 % du corpus pour l'apprentissage et le reste pour les tests.

Data 1:

Erreur en fonction du nombre de #means



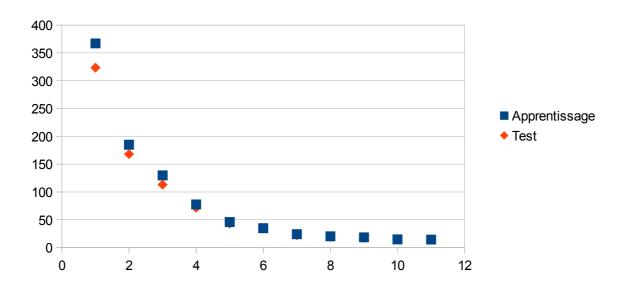
On voit bien que le nombre de classe à utiliser pour les k-means est bien de 5. En effet, l'erreur d'apprentissage diminue largement en passant de 4 à 5 classes mais très peu en passant de 5 à 6 classes.



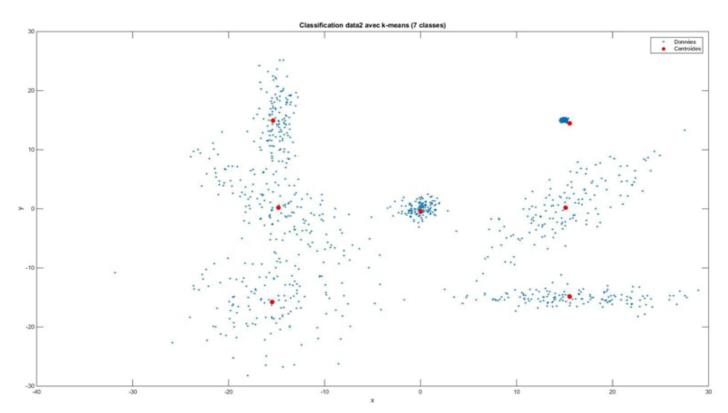
On voit bien ici les 5 centres de chaque classe sur les 5 différents nuages de points.

Data 2:

Erreur en fonction du nombre de #means



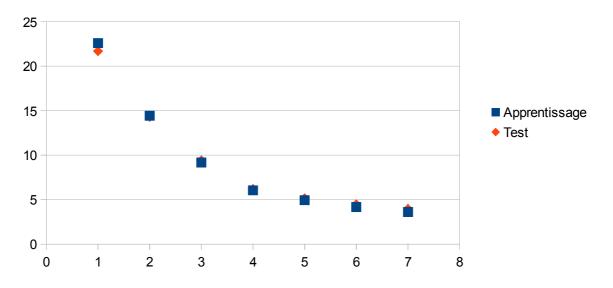
Sur cette courbe, on voit que le nombre de classes à utiliser pour les k-means est de 7.



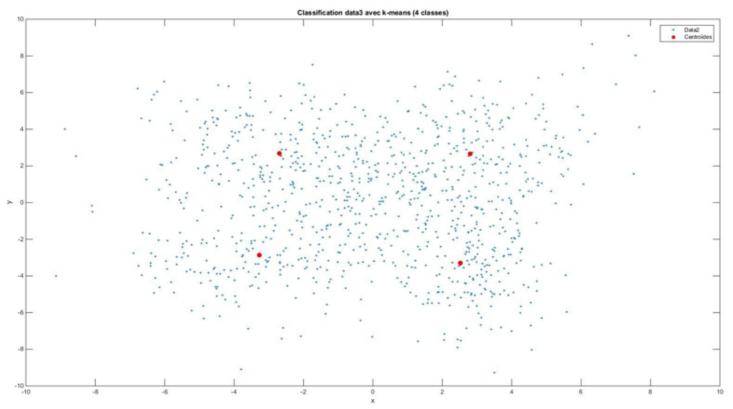
Ici 4 centres se trouvent naturellement sur les 3 nuages de droite et celui du milieu. Puis les 3 derniers centres se répartissent sur l'amas de gauche où il y a probablement recouvrement.

Data 3:

Erreur en fonction du nombre de #means



On voit que pour data3, il faut utiliser 4 classes.



Les 4 centres se répartissent sur l'ensemble des points.

Étude des données du sonar

Classification

Discrimination

Nous avons décidé de diviser le corpus de cette manière : 80 % pour l'apprentissage et 20 % pour les tests.

Après de très nombreux essais de différentes architectures, nous en avons retenus deux qui donne d'assez bon résultats.

Un perceptron multicouche avec 1 couche cachée : 60(L)x60(TanH)x2(G). Nous avons obtenu les matrices de confusion suivante pour un apprentissage de 500 époques :

Learn Confusion Matrix

	delivred			
d e		Mine	Rock	Sum
S	Mine	98,91% (91)	01,09% (1)	55,09% (92)
r	Rock	14,67% (11)	85,33% (64)	44,91% (75)
ď	Sum	61,08% (102)	38,92% (65)	92,81% (155 / 167)

Test Confusion Matrix

	delivred			
d e		Mine	Rock	Sum
	Mine	94,74% (18)	05,26% (1)	46,34% (19)
r	Rock	22,73% (5)	77,27% (17)	53,66% (22)
d	Sum	56,10% (23)	43,90% (18)	85,37% (35 / 41)

On voit bien que le perceptron classifie bien les mines et les rocks et à tendance à mal classé les rocks.

Et un perceptron multicouche avec 2 couches cachées : 60(L)x10(S)x10(T)x2(G). Nous avons obtenu les matrices de confusions suivantes pour un apprentissage de 500 époques :

Learn Confusion Matrix

	delivred			
d e		Mine	Rock	Sum
	Mine	83,70% (77)	16,30% (15)	55,09% (92)
r	Rock	06,67% (5)	93,33% (70)	44,91% (75)
ď	Sum	49,10% (82)	50,90% (85)	88,02% (147 / 167)

Test Confusion Matrix

	delivred			
d e		Mine	Rock	Sum
	Mine	94,74% (18)	05,26% (1)	46,34% (19)
r	Rock	18,18% (4)	81,82% (18)	53,66% (22)
ď	Sum	53,66% (22)	46,34% (19)	87,80% (36 / 41)

Pour celui-ci, nous obtenons des résultats similaires. Par contre, il faut remarquer que le deuxième classifie mieux les rocks et moins bien les mines, choses qui peut se révéler dangereux dans la vraie vie. Il sera préférable de mal classé un rock plutôt qu'une mine.

Spike-Timing-Dependent Plasticity

Classification de signaux de parole

Pour effectuer la classification, nous avons divisé le corpus comme suit : 67 % pour l'apprentissage et 33 % pour les tests. Après avoir testé plusieurs architectures, les meilleurs résultats ont été obtenu avec un perceptron sans couche cachée : 240(L)x39(G). Nous obtenons 83 % en apprentissage et 71 % en test. Il est très difficile d'obtenir de meilleurs résultats car le nombre d'entrées est trop

CARON Frédéric CHARLES Mickaël

élevés. D'ailleurs on peut remarquer sur la matrice de confusion, que certains phonèmes n'arrivent pas du tout à être bien classé.